Customer Segmentation Analysis of Starbucks Mobile App Users Using RFM and K-Means Clustering

Arnold Orlando Tarigan

Link Github:
https://github.com/arnoldorlandostory/Starbuck_MobileApp_CustomerSegmentation_ML.git
31 Maret 2026

1. Introduction

Amerika Serikat merupakan salah satu pasar konsumsi kopi terbesar di dunia dengan nilai industri mencapai USD 52.14 miliar pada tahun 2024 (*Coffee Beans Market Size, Share | Industry Report [2026-2034]*, n.d.). Walaupun begitu, saat ini terdapat pergeseran gaya hidup masyarakat Amerika yang cenderung semakin *fast-paced*, sehingga mendorong perubahan dalam kebiasaan konsumsi kopi yang sebelumnya *dine-in* menjadi konsep *grab and go*. Namun, dengan basis pelanggan yang sangat heterogen—mulai dari *occasional buyers* hingga *loyal daily customers*—Starbucks menghadapi tantangan dalam memberikan pengalaman yang personal dan strategi marketing yang tepat sasaran. Starbucks memerlukan pemahaman mendalam tentang segmentasi pelanggan berdasarkan pola pemesanan aktual untuk merancang strategi yang lebih presisi.

Penelitian ini bertujuan untuk melakukan segmentasi pelanggan Starbucks di Amerika Serikat menggunakan data pola pemesanan melalui aplikasi mobile. Metode yang digunakan adalah RFM Analysis (*Recency, Frequency, Monetary*) yang dikombinasikan dengan K-Means Clustering dan PCA (Principal Component Analysis) untuk mengidentifikasi segmen-segmen pelanggan dengan karakteristik yang berbeda.

2. Related Works

Penelitian yang melakukan analisis segmentasi pelanggan telah banyak dilakukan termasuk dalam pengaplikasian K-Means dan RFM Analysis. Tabianan et al. (2022) melakukan segmentasi pelanggan e-commerce menggunakan algoritma SAPK + K-Means pada 285 juta transaksi dari repositori MDEC Malaysia, namun tidak mengintegrasikan RFM Analysis dan tidak mempertimbangkan konteks loyalitas berbasis rewards membership. Yuliana et al. (2025) meneliti segmentasi pelanggan mall menggunakan K-Means yang dioptimasi dengan Elbow Method dan PCA dan metode *clustering* lainnya pada dataset Mall Customers Kaggle (200 data), namun tidak menggunakan kerangka RFM dan memiliki keterbatasan pada ukuran dataset yang sangat kecil. Pilli Sri Durga et al. (2023) membahas segmentasi pelanggan retail hipotetis untuk meningkatkan penjualan dan optimasi kampanye pemasaran, namun bersifat lebih konseptual tanpa integrasi RFM Analysis, PCA, maupun data dari kanal digital spesifik. John et al. (2023) mengeksplorasi lima algoritma clustering (K-Means, GMM, DBSCAN, Agglomerative, BIRCH) pada dataset UCI Online Retail UK (541.909 record) dengan kerangka RFM dan PCA, namun fokus pada retail umum tanpa spesialisasi kanal dan tidak menganalisis fitur perilaku digital seperti order_ahead dan rewards membership. Syahra et al. (2025) mengimplementasikan RFM Analysis dengan

K-Means Clustering pada 2.353 record transaksi retail skala kecil menggunakan Min-Max scaling dan Elbow Method, namun tidak menerapkan PCA dan beroperasi pada dataset kecil dari bisnis lokal tanpa fitur perilaku digital. Berbeda dengan penelitian-penelitian tersebut, penelitian ini memiliki pipeline yang lengkap dengan alur RFM Analysis dilanjutkan dengan standard scaler, PCA, dan K-Means serta fitur perilaku digital (rewards membership, cart size, order_ahead), menghasilkan segmentasi yang lebih presisi dan kontekstual untuk strategi personalisasi dalam ekosistem digital brand F&B spesifik.

3. Dataset

Data yang digunakan dalam melatih model diperoleh melalui platform Kaggle dengan judul "Starbucks Customer Ordering Patterns", yang di publish pada February 2026. Dataset tersebut terdiri dari 10000 baris data dengan 20 kolom fitur.

Hasil *validation* dan *exploratory data analysis* (EDA) pada seluruh dataset menemukan bahwa dataset tidak memiliki baris dengan *missing values* dan juga tidak memiliki duplikasi, selain itu tidak ditemukan data outlier sehingga data dapat dinyatakan telah *clean.* Selanjutnya, dari 20 fitur yang tersedia dalam dataset, dilakukan eliminasi terhadap beberapa fitur yang tidak merepresentasikan tujuan dari penelitian. Fitur yang dipilih agar dapat menjalankan tujuan penelitian antara lain: "customer_id", "order_id", "order_date", "order_channel", "is_rewards_member", "total_spend", "order_ahead". Dan juga dilakukan filter pada fitur "order_channel" untuk memilih transaksi pada *mobile app*. Selanjutnya dilakukan pengkodean untuk label pada fitur "is_rewards_member", "order_ahead", untuk mengubah data "True dan "False" menjadi 0 dan 1. Kemudian data dikelompokkan sesuai "customer_id", menciptakan data tabel sebagai berikut.

	customer_id	order_id_cnt	order_date_max	total_spend	rewards_member	order_ahead
0	CUST_00001	3	2025-05-26	49.73	0.666667	1.000000
1	CUST_00002	7	2025-10-30	123.62	0.571429	0.714286
2	CUST_00003	3	2025-10-08	50.55	0.666667	0.666667
3	CUST_00004	2	2025-08-01	32.58	0.500000	0.500000
4	CUST_00007	3	2024-12-10	64.36	0.666667	0.666667

4. Metode

a. RFM Analysis

RFM Analysis merupakan metode yang digunakan untuk segmentasi pelanggan berdasarkan 3 kriteria utama yaitu *recency, frequency*, dan *monetary*. *Recency* mengukur seberapa lama waktu sejak pelanggan terakhir kali melakukan transaksi, di mana pelanggan dengan transaksi yang lebih baru dianggap memiliki tingkat keterlibatan yang lebih tinggi. *Frequency* menunjukkan seberapa sering pelanggan melakukan transaksi dalam periode tertentu, yang mencerminkan tingkat loyalitas pelanggan terhadap suatu bisnis. Sementara itu, *Monetary* mengukur total nilai pengeluaran pelanggan, yang digunakan untuk menilai kontribusi finansial pelanggan terhadap perusahaan.

b. *Standard Scaler*

Standard Scaler adalah teknik normalisasi data yang digunakan untuk mengubah skala fitur sehingga memiliki distribusi dengan rata-rata (*mean*) 0 dan standar deviasi (*standard deviation*) 1. Proses ini dilakukan dengan cara mengurangi setiap nilai data dengan rata-rata fitur tersebut, kemudian membaginya dengan standar deviasinya. Tujuan utama dari Standard Scaler adalah untuk memastikan bahwa setiap fitur memiliki kontribusi yang seimbang dalam proses pemodelan. Secara matematis, transformasi yang dilakukan dapat dituliskan sebagai:

$$z = \frac{x - \mu}{\sigma}$$

Penulis rumus diatas dapat dibaca sebagai nilai z sama dengan x (nilai asli) dikurangi nilai mu (nilai rata-rata fitur) lalu dibagi dengan sigma (standar deviasi).

c. PCA

Principal Component Analysis (PCA) merupakan teknik mereduksi dimensi yang digunakan untuk mentransformasikan sekumpulan fitur yang saling berkorelasi menjadi sejumlah fitur baru yang tidak berkorelasi. Dalam penelitian ini PCA diterapkan menggunakan scikit-learn dengan solver yang ditetapkan "auto". Berdasarkan dokumentasi scikit-learn dan bentuk dataset yang digunakan, maka PCA diperkirakan menggunakan metode *eigen decomposition* (covariance_eigh).

Dalam proses PCA dengan metode *Eigen Decomposition,* setelah data dinormalisasi maka perlu dilakukan perhitungan matriks kovarians terlebih dahulu untuk menemukan sebaran data atau varians. Perhitungan matriks kovarians adalah sebagai berikut:

$$Cov(x, y) = \frac{1}{n} \sum_{i=1}^{n} (x_i - \bar{x})(y_i - \bar{y})$$

Rumus diatas dapat dimengerti sebagai kovarians(x,y) sama dengan rata-rata dari hasil perkalian selisih setiap data x terhadap rata-ratanya, dengan selisih setiap data y terhadap rata-ratanya. Perhitungan di atas akan menghasilkan kovarians yang berukuran n x n sesuai data yang dimiliki. Tahap selanjutnya adalah penerapan *eigen decomposition.* Pelaksanaan *eigen decomposition* bertujuan untuk menguraikan sebuah matriks menjadi komponen-komponen dasar berupa *eigenvalue* dan *eigenvector. Eigenvector* melambangkan arah khusus dimana terdapat kombinasi dari semua fitur. Sedangkan *eigenvalue* menunjukan besarnya variansi di arah tersebut. Secara matematis, perhitungan *eigen decomposition* yang dilakukan dapat dituliskan sebagai:

$$\Sigma v = \lambda v$$

Rumus diatas dapat dibaca sebagai sigma (matriks kovarians) dikali v (*eigenvector)* sama dengan lambda (*eigenvalue*) dikali v (*eigenvector*). Jumlah v atau vektor yang dihasilkan dari perhitungan diatas menunjukan jumlah *principal component* (PC). Selanjutnya untuk menemukan jumlah PC yang tepat untuk mereduksi dimensi yang dimiliki, maka dilakukan sorting dan filtering terhadap PC dengan *eigenvalue* yang memiliki varian rendah. Sehingga PC yang telah ditentukan berdasarkan hasil filtering mampu merepresentasikan keseluruhan data tanpa menggunakan keseluruhan fitur.

d. K-Means

K-Means merupakan salah satu metode clustering yang digunakan untuk mengelompokkan data berdasarkan tingkat kemiripan data. Secara matematis, K-Means bekerja dengan meminimalkan fungsi objektif berupa jumlah kuadrat jarak antara setiap data dengan pusat klaster (centroid) terdekatnya, sehingga data dalam satu klaster memiliki karakteristik yang saling mendekati. Tahapan dalam metode K-Means yang pertama yaitu menentukan nilai K atau kluster optimal yang akan digunakan. Penentuan klaster pertama kali dilakukan secara random dengan range tertentu. Dalam iterasi pertama, K-Means maka akan menentukan centroid secara random dan akan menghitung jarak antara tiap objek dengan centroid. Setelah jarak antara setiap data dan centroid dihitung, setiap data akan di-*assign* ke klaster dengan jarak terdekat. Selanjutnya, centroid diperbarui dengan menghitung rata-rata dari seluruh data dalam masing-masing klaster.

$$d(x_i, \mu_k) = \sqrt{\sum_{j=1}^{n} (x_{ij} - \mu_{kj})^2}$$

Proses *assignment* dan *update centroid* ini dilakukan secara iteratif hingga tidak terjadi perubahan signifikan atau telah mencapai kondisi konvergen, di mana nilai fungsi objektif terus menurun dan mencapai minimum.

$$\frac{1}{n} \sum_{i=1}^{n} \left\| x_i - z_{c_i} \right\|^2$$

Penentuan jumlah klaster optimal (K) dilakukan menggunakan metode seperti *Elbow Method* dan *Silhouette Score. Elbow Method* digunakan untuk melihat penurunan nilai inertia, sedangkan *Silhouette Score* mengukur kualitas pemisahan antar klaster. Setelah nilai K optimal diperoleh, K-Means dijalankan kembali untuk menghasilkan klaster akhir yang lebih optimal dan representatif.

5. Experiments, Results, and Discussion

a. Experiments

Beberapa fitur digunakan pada data yang telah dikelompokkan digunakan untuk membuat RFM Analysis. *Recency* menggunakan fitur "customer_id" dan " max_date" untuk menemukan jarak dari tanggal transaksi maksimal di dataset (dianggap sebagai hari terakhir pendataan) dengan transaksi maksimal setiap pelanggan.

```
#Menghitung Recency
#Mengambil tanggal maksimal pada dataset
max_date = data_groupby['order_date_max'].max()

#Menghitung jarak tanggal maksimal data dengan maksimal pengguna
data_groupby['recency'] = (max_date - data_groupby['order_date_max']).dt.days
data_groupby
```

	customer_id	order_id_cnt	order_date_max	total_spend	rewards_member	order_ahead	recency
0	CUST_00001	3	2025-05-26	49.73	0.666667	1.000000	218
1	CUST_00002	7	2025-10-30	123.62	0.571429	0.714286	61
2	CUST_00003	3	2025-10-08	50.55	0.666667	0.666667	83
3	CUST_00004	2	2025-08-01	32.58	0.500000	0.500000	151
4	CUST_00007	3	2024-12-10	64.36	0.666667	0.666667	385

Frequency menggunakan fitur "customer_id" dan "order_id_cnt" untuk menemukan jumlah frekuensi transaksi yang dilakukan pelanggan melalui *mobile app.*

```
#Menghitung Frequency
#Frequency telah didapatkan dari hasil count order_id saat groupby
data_groupby.rename(columns={'order_id_cnt': 'frequency'}, inplace=True)
data_groupby
```

	customer_id	frequency	order_date_max	total_spend	rewards_member	order_ahead	recency
0	CUST_00001	3	2025-05-26	49.73	0.666667	1.000000	218
1	CUST_00002	7	2025-10-30	123.62	0.571429	0.714286	61
2	CUST_00003	3	2025-10-08	50.55	0.666667	0.666667	83
3	CUST_00004	2	2025-08-01	32.58	0.500000	0.500000	151
4	CUST_00007	3	2024-12-10	64.36	0.666667	0.666667	385

Monetary menggunakan fitur "customer_id", "total_spend" untun menemukan jumlah nilai transaksi yang dilakukan pelanggan melalui *mobile app.*

```
#Menghitung Monetary
#Monetary telah didapatkan dari hasil penjumlahan total_spend saat groupby
data_groupby.rename(columns={'total_spend': 'monetary'}, inplace=True)
data_groupby.head()
```

	customer_id	frequency	order_date_max	monetary	rewards_member	order_ahead	recency
0	CUST_00001	3	2025-05-26	49.73	0.666667	1.000000	218
1	CUST_00002	7	2025-10-30	123.62	0.571429	0.714286	61
2	CUST_00003	3	2025-10-08	50.55	0.666667	0.666667	83
3	CUST_00004	2	2025-08-01	32.58	0.500000	0.500000	151
4	CUST_00007	3	2024-12-10	64.36	0.666667	0.666667	385

Ketiga analisis diatas kemudia disatukan beserta dengan fitur lain yang digunakan dalam analisis meliputi: “recency” (hari sejak transaksi terakhir), “frequency” (jumlah transaksi), “monetary” (total pengeluaran), “avg_cart_size” (rata-rata ukuran keranjang), “rewards_member” (status keanggotaan rewards), dan “order_ahead” (penggunaan fitur pemesanan di muka).

	recency	frequency	monetary	rewards_member	order_ahead
0	218	3	49.73	0.666667	1.000000
1	61	7	123.62	0.571429	0.714286
2	83	3	50.55	0.666667	0.666667
3	151	2	32.58	0.500000	0.500000
4	385	3	64.36	0.666667	0.666667

Normalisasi data dilakukan menggunakan StandardScaler untuk memastikan semua fitur memiliki skala yang sama dengan mean 0 dan standard deviation 1. Setelah normalisasi, PCA diterapkan untuk mereduksi dimensi data dengan tujuan menghilangkan redundansi dan noise sambil mempertahankan varians yang signifikan. Hasil analisis PCA menunjukkan distribusi variance untuk setiap jumlah komponen yang berbeda.

```
komponen n = 1 memiliki variance sebesar 45.281648771344415
komponen n = 2 memiliki variance sebesar 65.36050024796226
komponen n = 3 memiliki variance sebesar 85.3306528123386
komponen n = 4 memiliki variance sebesar 99.14959678341629
komponen n = 5 memiliki variance sebesar 99.99999999999999

n_components : 4
```

Berdasarkan hasil diatas, dapat dilihat bahwa 4 komponen pertama mampu menjelaskan 99.1% total variance dalam data. Pemilihan 4 komponen dipilih sebagai keseimbangan antara reduksi dimensi dengan tetap mempertahankan sebagian besar informasi dalam data. Selanjutnya penentuan klaster dilakukan dengan menggunakan elbow method dan silhouette method. Berdasarkan perhitungan kedua metode, ditentukan bahwa jumlah klaster yang sesuai dalam penelitian ini yaitu 9 klaster.

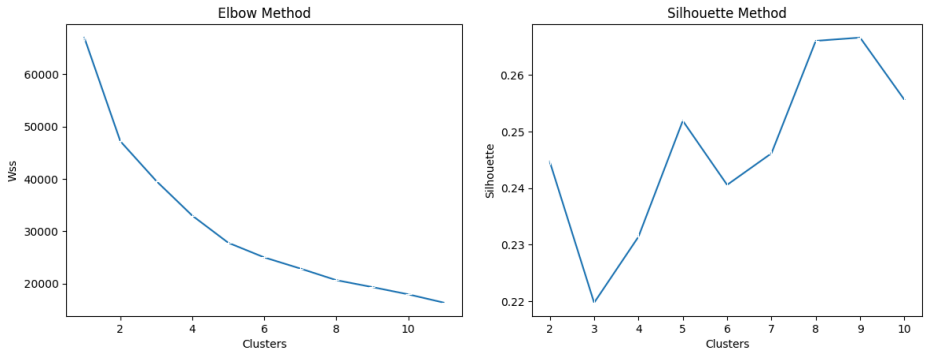

b. Results

Setelah menentukan K=9 sebagai jumlah klaster optimal, dilakukan kembali K-Means dengan K yang sudah optimal dan dilakukan *inverse transformation* untuk mengembalikan centroid klaster dari PCA menjadi fitur. Hasil dari pada clusterisasi 9 klaster adalah sebagai berikut:

	cluster	recency	frequency	monetary	rewards_member	order_ahead	Jumlah
0	Cluster 1	99.643078	6.078012	112.600017	0.636636	0.711448	2220
1	Cluster 2	101.589985	3.314143	59.517113	0.462518	0.898019	2059
2	Cluster 3	322.978656	1.286456	21.815969	-0.000006	0.992698	846
3	Cluster 4	222.719965	2.040183	35.771982	0.270199	0.295140	1259
4	Cluster 5	521.882213	1.304272	23.149027	0.994195	0.984129	861
5	Cluster 6	392.358817	2.952901	54.168335	0.566749	0.796012	1247
6	Cluster 7	362.919132	1.571811	27.481876	0.979986	0.152394	1016
7	Cluster 8	118.012480	3.588564	64.869323	0.807269	0.568321	2735
8	Cluster 9	158.937071	1.810755	30.888284	0.999993	0.994509	1277

c. Discussion

Kesembilan segmentasi pelanggan dapat diinterpretasikan sebagai berikut:

Klaster	Tipe Customer	Penjelasan Karakteristik	Strategi Marketing
1	Champions (2220)	Merupakan segmen pelanggan paling berharga. Karena mereka sangat aktif, sering bertransaksi, dan memberikan kontribusi pendapatan terbesar. Selain itu mereka juga merupakan member yang dominan memesan terlebih dahulu melalui aplikasi. Klaster ini adalah segmen customer yang harus dipertahankan dengan segala cara.	Strategi difokuskan pada retensi dan peningkatan loyalitas melalui reward eksklusif, personalisasi penawaran, serta program referral. Pengembangan ke tier premium juga penting untuk memperkuat keterikatan dan mencegah perpindahan ke kompetitor.
2	Loyal Customers (2059)	Pelanggan loyal yang sangat menghargai kemudahan (order ahead tinggi). Mereka adalah regular pelanggan dengan potensi untuk dikembangkan menjadi Champions.	Fokus utama adalah meningkatkan frekuensi transaksi dan mendorong mereka menjadi Champions melalui program loyalty, optimalisasi fitur order ahead, serta strategi up selling untuk menaikkan nilai transaksi.
3	Lost Non-Members (846)	Segmen pelanggan yang hampir tidak aktif selama hampir setengah tahun, bukan rewards member, dan memiliki engagement minimal. Kemungkinan besar sudah beralih ke competitor atau berhenti bertransaksi melalui channel *mobile app*.	Diperlukan strategi win-back agresif dengan diskon besar atau voucher gratis, disertai dorongan untuk bergabung ke program rewards dan pengumpulan feedback untuk memahami penyebab churn.
4	Hibernating Low Engagement (1259)	Pelanggan yang saat ini sedang tidak aktif, walaupun dahulu pernah. Segmen ini memiliki tingkat engagement yang rendah dan belum memanfaatkan fitur yang tersedia pada aplikasi.	Strategi re-engagement dilakukan secara bertahap melalui promo comeback, meningkatkan ketertarikan pada fitur order ahead, serta promosi

		Walaupun begitu, masih terdapat potensi untuk kembali aktif.	musiman untuk menghidupkan kembali minat pelanggan.
5	Completely Lost Members (861)	Ini adalah akun reward member yang kemungkinan *mobile app* sudah tidak aktif lagi dan memilih transaksi melalui channel offline.. Mereka pernah *engaged* dengan menjadi member, dan memesan terlebih dahulu melalui aplikasi tetapi sudah 1.5 tahun tidak terdengar kabarnya. Kemungkinan besar menggunakan channel lain.	Pendekatan berupa upaya terakhir dengan penawaran sangat menarik dan pengingat poin sebelum kadaluarsa. Jika tidak berhasil, segmen ini dapat dipertimbangkan untuk dikeluarkan dari fokus pemasaran.
6	At-Risk Active Members (1247)	Ini adalah rewards members yang memiliki resiko berpindah atau tidak lagi menggunakan *mobile app*. Mereka sering melakukan transaksi dengan nominal yang tinggi, tetapi belakangan mereka jarang melakukan pembelian menunjukkan mereka mulai menjauh dari penggunaan *mobile app*.	Segmen ini membutuhkan intervensi cepat karena menunjukkan tanda-tanda penurunan aktivitas. Memerlukan intervensi cepat melalui penawaran eksklusif, personalisasi berbasis histori pembelian, dan kampanye multi-channel untuk mencegah churn.
7	Dormant High-Loyalty Members (1016)	Segmen ini memiliki pelanggan dengan tingkat members yang tinggi namun dormant. Mereka menjadi member tetapi tidak aktif. Kemungkinan mereka adalah *occasional/seasonal buyers* atau menggunakan channel lain. Tingkat *order ahead* yang rendah menunjukkan bahwa pelanggan di segmen ini lebih bersifat impulsif atau lebih menyukai pembelian menggunakan *mobile app* di tempat	Meskipun memiliki tingkat membership yang tinggi, segmen ini kurang aktif dan memiliki adopsi teknologi rendah. Oleh karena itu, strategi difokuskan pada edukasi penggunaan aplikasi dan fitur order ahead, serta pemberian penawaran khusus berbasis aplikasi untuk meningkatkan aktivitas.
8	Potential Loyalists (2735)	Segmen pelanggan dengan potensial tinggi untuk menjadi Champions. Mereka memiliki jumlah pembelian dengan nominal yang tinggi, mayoritas sudah jadi member, dan masih aktif. Dengan strategi yang tepat, mereka bisa ditingkatkan menjadi Champions.	Segmen ini memiliki potensi besar untuk berkembang menjadi pelanggan terbaik, sehingga strategi harus difokuskan pada peningkatan engagement dan frekuensi. Fokus pada peningkatan engagement melalui gamifikasi, dorongan naik tier membership, serta eksplorasi produk untuk meningkatkan frekuensi dan nilai transaksi.
9	Need Attention Members (1277)	Segmen pelanggan ini merupakan rewards members yang sangat engaged dengan platform, tetapi tingkat aktivitas transaksi mulai menurun dan menjauh. Terdapat kemungkinan pelanggan ini sedang mengurangi pembelian kopi dikarenakan faktor eksternal seperti finansial.	Strategi untuk segmen ini berfokus pada peningkatan value perception karena mereka cenderung price-sensitive. Penawaran seperti diskon, happy hour, atau multiplier rewards dapat membantu meningkatkan frekuensi pembelian. Model langganan juga dapat menjadi solusi untuk meningkatkan konsistensi pembelian.

d. Berdasarkan data diatas, strategi marketing perlu disesuaikan agar tidak hanya berfokus pada tipe pelanggan, tetapi juga mempertimbangkan skala dampaknya

sesuai dengan jumlah pelanggan dalam klaster tersebut. Pada prioritas pertama, yaitu segmen *high value* (Klaster 1, 2, dan 8), dimana ketiga klaster memiliki nilai transaksi dan frekuensi tinggi, dan juga juga mendominasi jumlah pelanggan. Oleh karena itu, Starbucks perlu mempertahankan dan menjaga loyalitas pelanggan serta mendorong peningkatan aktivitas pada segmen yang masih berpotensi menjadi Champions.

Pada prioritas kedua, yaitu segmen at-risk (Klaster 4, 6, dan 9), pendekatan perlu lebih diperkuat karena ketiganya memiliki jumlah pelanggan yang cukup besar dan masih berpotensi untuk diaktifkan kembali. Dengan jumlah yang signifikan, peningkatan dalam frekuensi atau transaksi dari segmen ini dapat memberikan dampak terhadap *revenue.* Oleh karena itu, strategi yang tepat adalah menjalankan campaign yang lebih personal, seperti penawaran yang disesuaikan dengan perilaku pelanggan serta meningkatkan ketertarikan pada fitur aplikasi dengan promo atau voucher untuk meningkatkan kembali engagement.

Sementara itu, pada prioritas ketiga, yaitu segmen *low-value* (Klaster 3, 5, dan 7), meskipun jumlah pelanggan cukup signifikan, performanya rendah dari sisi frekuensi, nilai transaksi, dan tingkat keaktifan. Hal ini menunjukkan bahwa potensi return dari segmen ini terbatas. Strategi yang tepat adalah melakukan *win-back* campaign secara terbatas dan berbiaya rendah. Jika tidak terdapat respons setelah beberapa kali percobaan, maka lebih baik untuk berfokus pada segmen pelanggan yang lain.

6. Conclusion and Future Work

Penelitian ini berhasil melakukan segmentasi pelanggan pengguna *mobile app* Starbucks menggunakan kombinasi RFM Analysis, Standard Scaler, PCA, dan K-Means Clustering. Dari 10.000 data transaksi, berhasil diidentifikasi 9 segmen pelanggan yang berbeda dengan karakteristik unik masing-masing, mulai dari Champions yang paling berharga hingga Completely Lost Members yang hampir tidak aktif. Hasil analisis PCA menunjukkan bahwa 4 komponen utama mampu merepresentasikan 99,1% total varians data, sehingga reduksi dimensi dapat dilakukan tanpa kehilangan informasi yang signifikan. Dengan jumlah klaster optimal K=9 yang ditentukan melalui Elbow Method dan Silhouette Score, setiap segmen dapat diinterpretasikan secara bermakna dan memberikan rekomendasi strategi pemasaran yang spesifik dan terarah bagi Starbucks untuk meningkatkan retensi, re-engagement, serta konversi pelanggan potensial.

Untuk penelitian selanjutnya, terdapat beberapa arah pengembangan yang dapat dilakukan. Pertama, perlu dilakukan validasi model dengan data transaksi dari channel lain seperti *in-store* dan *drive-thru* untuk menguji konsistensi segmentasi lintas kanal. Kedua, eksplorasi algoritma clustering lain seperti DBSCAN atau Gaussian Mixture Model dapat dibandingkan dengan K-Means untuk mengevaluasi kualitas segmentasi yang dihasilkan. Ketiga, penambahan fitur perilaku seperti jenis produk yang sering dibeli dan waktu pemesanan dapat memperkaya profil setiap segmen. Terakhir, penelitian ini dapat dikembangkan menjadi sistem segmentasi dinamis yang memperbarui klaster secara berkala sesuai perubahan perilaku pelanggan dari waktu ke waktu.

7. References

Coffee beans Market Size, Share | Industry Report [2026-2034]. (n.d.). https://www.fortunebusinessinsights.com/coffee-bean-market-111087

Durga, P. S., Paulson, J. A., & Srinivasareddy, M. (2023). Customer segmentation analysis for improving sales using clustering. *International Journal of Science and Research Archive*, *9*(2), 708–715. https://doi.org/10.30574/ijsra.2023.9.2.0663

John, J. M., Shobayo, O., & Ogunleye, B. (2023). An exploration of clustering algorithms for customer segmentation in the UK retail market. *Analytics*, *2*(4), 809–823. https://doi.org/10.3390/analytics2040042

Syahra, Y., Fadlil, A., & Yuliansyah, H. (2025). Customer segmentation using RFM and K-Means clustering to support CRM in retail industry. SinkrOn, 9(3), 1120–1131. https://doi.org/10.33395/sinkron.v9i3.14907

Tabianan, K., Velu, S., & Ravi, V. (2022). K-Means clustering approach for intelligent customer segmentation using customer purchase behavior data. *Sustainability*, *14*(12), 7243. https://doi.org/10.3390/su14127243

Yuliana, R. E., Ulya, D. M., & Jamhuri, M. (2025). Mall customer segmentation using K-Means clustering optimized by the elbow method. *Jurnal Riset Mahasiswa Matematika*, *4*(5), 273–286. https://doi.org/10.18860/jrmm.v4i5.33389